


第1讲 - 商业分析思维及数据特征描述

张建章

阿里巴巴商学院
杭州师范大学

2026-05



- 1 第一节：商业分析的方法分类
- 2 第二节：数据决策的组织架构
- 3 第三节：数据处理的商业伦理
- 4 第四节：商业数据的多维尺度
- 5 第五节：数据透视的多维决策
- 6 第六节：数据呈现的可视化图
- 7 第七节：数据分布的属性特征
- 8 第八节：大模型智能体在商业数据分析中的应用

商业数据分析的方法主要有三大类，描述性分析、预测性分析、规定性分析。分析数据时既要遵守技术伦理（避免过拟合）也要遵守商业道德伦理（避免隐私滥用）。数据可以从多个角度进行分类，并可以根据分析目标使用不同的可视化图表进行呈现。给定一组或多组实际数据时，可以通过计算多类指标来刻画数据分布的属性特征，如集中趋势、离散趋势、频数分布形态（形状）、不同数据之间的统计相关性。

商业分析的三种方法分类

- **描述性分析 (Descriptive Analytics):** 发生了什么？利用海量数据（包含文本、评价等非结构化数据）建立仪表盘。在我的自然语言处理（NLP）研究中，常常通过挖掘淘宝/京东的消费者评论文本，来构建“客户画像”。
- **预测性分析 (Predictive Analytics):** 将会发生什么？利用统计模型与机器学习，寻找历史数据中的趋势与因果（如时间序列、回归分析）。
- **规定性分析 (Prescriptive Analytics):** 我们该怎么做？结合管理科学的优化模型（如线性规划），在资源约束下寻找利益最大化的最优解。

1. 第一节：商业分析的方法分类

现代商业分析：从后视镜到方向盘

数据驱动的决策进化之路


1 描述性分析 Descriptive Analytics

发生了什么？

业务仪表盘 (总结过去)



销售额趋势 (万元)



渠道占比



客户评论 (非结构化文本)



产品质量很好，包装也很精美，配送很快，体验非常完美！
性价比不错，但希望优惠活动能更多一些。
客服响应慢，退换货流程复杂，不太满意这次购物体验。

包装精美

质量很好

性价比

物流快

价格偏高

客服差

退换货慢

客户画像 (示例)



高价值客户-张女士
28岁 | 上海
年消费: 8,600 元
偏好: 美妆、护肤
活跃度: 高
生命周期阶段: 成长期

RFM 评分



2 预测性分析 Predictive Analytics


将会发生什么？

需求预测 (时间序列预测)



趋势与回归分析

销售额与营销投入的关系



预测模型 (机器学习)

流失风险预测 (示例)



预测输出 (示例)



3 规定性分析 Prescriptive Analytics

我们该怎么做？

决策目标

最大化利润 (万元)
在资源与约束条件下



最优决策方案

最优解
预期利润: 3,860 万元

资源分配决策 (示例)

资源/产品	可用资源	方案建议分配	预期贡献 (万元)
产品A	1,000 件	600 件 (60%)	1,920
产品B	800 件	400 件 (50%)	1,280
产品C	600 件	300 件 (50%)	660
合计	2,400 件	1,300 件	3,860

约束条件

- 总库存 $\leq 2,400$ 件
- 预算 ≤ 500 万元
- 生产能力 $\leq 1,500$ 件
- 最小需求约束
- 渠道覆盖要求

优化求解过程 (线性规划)



行动建议 (可执行)

- 增加产品A推广: 投资前期收益, 预期提升销量 18%
- 优化库存补货: 提前补货A、B, 降低缺货风险
- 定向营销高风险客户: 发放专属优惠券, 挽回潜在流失
- 调整渠道组合: 加大线上渠道, 提升整体毛利

看清过去，理解业务与客户

预见未来，提前布局与规划

优化决策，选择最优行动方案

后视镜：看清过去

前挡风：预见未来

方向盘：掌控未来


三类商业分析的行业场景应用

- **落地化思考：**结合我们在座各位来自数字经济与先进制造的背景，看看三类分析方法如何赋能实际业务。

分析支柱	场景一：杭州某美妆电商	场景二：宁波某汽配制造
描述性分析	提炼海量小红书KOL文本评价，监控品牌情感倾向	利用IoT传感器数据，监控生产线各节点的良品率波动
预测性分析	基于历史促销与季节效应，预测“双十一”各单品销量	利用机器学习预测高价值数控机床的主轴故障（预测性维护）
规定性分析	在营销预算约束下，优化广告投放组合以最大化ROI	求解多工厂、多仓库的物流系统最低成本配送方案

多层次决策视角下的分析方法赋能

- **业务落地：**三类分析方法和结果，最终是为不同层级的决策者服务的。
 - **企业高层 (战略与风险)：**关注“规定性分析”给出的资源最优配置。容忍预测误差，但要求决策系统具备抵御风险的鲁棒性。
 - **业务骨干 (执行与说服)：**关注“描述性与预测性分析”。用严谨的数据逻辑和可视化图表向上级证明资源申请的合理性。



数据分析技术链条的实战落地


- **制造业典型排产案例：**某汽车底盘系统制造企业，其车间主管在面对**多机型联合排产**时，如何通过数据分析之“术”化解工时与原材料约束，实现企业利润最大化？

核心技术链条（术）	底盘系统制造企业的商业实战落地应用
1. 数据准备与重构	收集车间粗糙、带有噪声的原始排班与焊接/装配日志，通过电子表格工具重构为清晰的单件工时消耗、固定成本与变动成本对照表。
2. 数学模型近似表征	将车间排产问题抽象为数学模型。明确决策变量（各型号底盘产量）、目标函数（总利润最大）及关键约束条件（设备工时上限、原材料供应能力）。
3. 算法自动求解与推演	借助优化求解器软件，由计算机自动在后台调用系统化求解算法（如线性规划单纯形法），将复杂的数学计算自动化，直接输出最优排产方案。

注：商业和开源的求解器软件

数据分析中的商业伦理规范

- **过度拟合：**预测模型如果过分迎合历史数据的噪音（如强行使用六次多项式拟合销售数据），不仅会导致决策失误，也是一种不严谨的分析操守。



- **算法偏见与隐私红线：**
 - 在使用机器学习和NLP进行客户画像与信用评分时，算法极易继承人类历史数据中的隐性歧视。
 - “大数据杀熟”与滥用客户隐私，是悬在现代商业分析头顶的达摩克利斯之剑。
- **道德准则：**我们学习模型与算法，不仅为了追求利润最大化，更要确保技术在法治和向善的轨道上运行。

商业数据的多维尺度度量

● 定类数据与定序数据（定性视角）：

- 定类：区分范畴（如行业大类：制造业、互联网），求和与均值无意义。
- 定序：存在顺序（如客户满意度：很好5, 较好4, 一般3），差距无法精确量化。

● 定距数据与定比数据（定量视角）：


- 定距：可比差距（如生产车间温度），零点为相对参照，不可做乘除倍数分析。
- 定比：拥有绝对零点（如营收、利润），零代表彻底不存在，可计算倍数关系。

数据类型	数学运算限制	典型商业应用场景
定类/定序	仅限频数、百分比统计	品牌偏好度、市场调研问卷
定距/定比	加减乘除、均值与标准差	财务绩效评估、供应链交期 ¹

¹从客户下单开始，到产品最终交付完成所需要的时间。


截面数据的定义及商业场景

- **截面数据：** 某一确定时点上多个个体的状态。例如，长三角制造生态圈内，30家制造业企业在2026年第一季度的研发投入总额。




时间序列数据的趋势追踪及应用

- **时间序列数据：** 同一特定对象在连续时间段内的变化轨迹。例如，某跨境电商平台过去5年来每月的海外订单交易总量。



面板数据的多维动态演进分析

- **面板数据：**追踪长三角生态圈内 4 家不同赛道的企业（智能光电、汽车底盘、生物医疗、跨境电商）在过去 5 年间的年度净利润率的动态演进。



截面维度：在指定的年份（如 2026 年），横向并列对比 4 家企业的净利润率，暴露的是行业先天盈利模式的“异质性”（如医疗器械的高毛利 vs 跨境电商的剧烈波动）。

时间序列维度：对任意一家特定企业（如智能光电），纵向追踪其 5 年来的轨迹，展现的是该企业在技术周期和组织成长中的“演进趋势”。

多维数据透视的结构化洞察

- **数据多维透视：**将零散的海量原始数据通过“行字段”、“列字段”和“值汇总方式”进行**交叉聚合**。
- **案例背景：某集团赛道运营数据诊断**
 - **数据规模：**涵盖某集团四大赛道（智能硬件、汽车零部件等）的 5,000 余条模拟销售流水（如下表所示）。
 - **多维属性：**包含“大区、产品、渠道、营收、营销成本”等核心经营变量。

大区	产品品类	产品名称	渠道类型	销量	销售额	营销费用
华东大区	汽车零部件	轻量化轮毂	渠道分销	39	48737.85	3966.28
华南大区	汽车零部件	轻量化轮毂	线下直销	37	46915.08	4746.56
华东大区	智能硬件	激光传感器	线上电商	35	11197.8	1537.04
华东大区	智能硬件	智能手环V2	渠道分销	80	21959.16	3196.96
华北大区	医疗耗材	高分子医用导管	渠道分销	19	2833.16	362.02
华北大区	汽车零部件	精密齿轮	渠道分销	42	47954.6	5541.73
华南大区	汽车零部件	液压底盘件	渠道分销	24	31333.99	3190.51
华东大区	智能硬件	车载智能模块	线上电商	76	21876.13	2164.54
华东大区	汽车零部件	液压底盘件	线上电商	70	75640.27	8474.49
华东大区	汽车零部件	液压底盘件	线下直销	97	106210.95	11382.68
华东大区	医疗耗材	高分子医用导管	线下直销	96	15832.51	1972.83
华东大区	医疗耗材	诊断试剂盒	线上电商	32	4740.48	394.09
华东大区	医疗耗材	诊断试剂盒	线上电商	99	15469.78	2009.39

操作一：全局透视下的业务基石识别

- **核心目标：**全景审视公司跨赛道、跨区域的营收分布，识别支撑业绩的“压舱石”。
- **管理操作：**构建**全局营收色阶表**。以“产品品类”为行、“大区”为列，对销售总额执行跨行跨列的全局热力映射。

【董事会宏观基线】2025–2026年 公司核心赛道 × 业务大区 全局营收大盘透视表
(颜色越深代表营收贡献越大)

大区	华东大区	华北大区	华南大区	西部大区
产品品类				
医疗耗材	415.2 万元	125.4 万元	207.0 万元	79.0 万元
智能硬件	1,586.1 万元	510.7 万元	780.9 万元	305.9 万元
汽车零部件	6,828.8 万元	2,013.4 万元	3,169.5 万元	1,199.4 万元

- **决策洞察：**
 - 瞬时锁定制撑公司业绩的“绝对现金牛”，华东大区汽车零部件赛道。
 - 为一把手提供“战略重心”确认，确保核心大盘的资源优先级。


操作二：纵向诊断下的结构性风险揭示

- **核心目标：**在海量流水中寻找业绩波动的“黑天鹅”，排查特定区域表现异常的根源。
- **管理操作：**执行多层嵌套透视与分组比对。下钻至“大区 → 品类 → 渠道”三级维度，通过多维分组色阶图（柱状图）对比各渠道业绩结构。

	渠道类型	渠道分销	线上电商	线下直销
大区	产品品类			
华东大区	医疗耗材	225,242 元	259,155 元	190,332 元
	智能硬件	857,268 元	180,420 元	915,834 元
	汽车零部件	3,623,203 元	4,281,461 元	3,537,013 元
华北大区	医疗耗材	72,844 元	95,334 元	42,977 元
	智能硬件	240,174 元	229,885 元	272,997 元
	汽车零部件	927,387 元	1,709,339 元	933,133 元
华南大区	医疗耗材	111,717 元	115,620 元	119,193 元
	智能硬件	431,379 元	452,812 元	546,264 元
	汽车零部件	2,316,534 元	2,532,670 元	2,671,144 元
西部大区	医疗耗材	47,911 元	41,421 元	18,505 元
	智能硬件	144,258 元	163,483 元	240,784 元
	汽车零部件	1,033,234 元	194,651 元	739,282 元

5. 第五节：数据透视的多维决策

2026年Q1 各大区【智能硬件】细分渠道销售额横向对标



● 决策洞察：

- 识破华东大区智能硬件的**渠道断裂**：其线上电商收入远低于线下且被其他小体量大区反超。
- 结论：线索直指华东线上运营团队失灵，而非大环境问题。

操作三：战略对齐下的资源重组驱动


- 核心目标：评估营销投入的转化效率，在组织范围内进行资源的优化调配。
- 管理操作：构建**营销费用率热力矩阵**， $\text{营销费用率} = \frac{\sum \text{营销费用}}{\sum \text{销售额}} \times 100\%$

【董事会决策看板】2026年Q1 各赛道营销资源费用率横向调配
矩阵（红区预警，绿区安全）

大区	华东大区	华北大区	华南大区	西部大区
产品品类				
医疗耗材	11.8 %	11.3 %	11.3 %	12.3 %
智能硬件	20.3 %	10.7 %	11.2 %	11.0 %
汽车零部件	11.4 %	12.2 %	11.6 %	11.1 %

- 决策洞察：
 - 华东地区的智能硬件为“获客黑洞”（费用率 20.3%，远超公司 $\approx 11\%$ 的基线），汽车零部件为该地区的潜在“效率高地”。
 - 冻结低效黑洞预算，向高转化洼地增资，实现数据驱动的决策闭环。


堆叠柱状图：表示不同系列数据占总量的比例关系



- 不同赛道企业的营收渠道特征截然不同：先进制造与传统实业由区域分销主导，而数字科技与跨境电商则分别由线上直销和海外贸易占据绝对统治地位。


散点图：表示两个变量数值之间的相关关系

校友企业分析：年度研发投入与营收增长率共振效应（散点图）




- **创新驱动红利（强正相关）：**散点整体自左下向右上蔓延，呈现出强烈的正线性相关特征。表明研发开支带来的技术溢价驱动了营收的增长。

气泡图：对一组数据的三个指标进行展示和比较



- “市场土壤、业务爆发与地缘资源”的三维共振：杭州与宁波凭借极高的数字化生态与庞大的订单量，叠加密集的校友网络，构成了无可替代的黄金主战场；而南昌则在营商环境、业务体量与本地资源上均面临全方位的边缘破局挑战。

雷达图：表示两组或多组变量相应数值的多维度比较



- 行业特征多维对比：先进制造侧重精密产线与供应链，主打“生产与安全”的稳健防守；数字科技呈现高杠杆形态，追求“收益与成长”的同时需严控流动性风险。

集中趋势指标的管理决策应用

- **算术均值**： $\mu = \frac{1}{n} \sum_{i=1}^n x_i$ 。反映系统的平均水位（如网点的平均销售额）。
缺陷：**极易受极端值（Outliers）扭曲**。
- **中位数**：按大小排列后居于 50% 处的数值（偶数个则取中间两者均值）。
反映结构的中坚力量，不受极端值（如，暴利或巨亏）的影响。
- **众数**：出现频数最高的标志值。反映市场中**最具普适性**的“典型消费者行为”或最畅销产品定价区间。

集中趋势指标	管理决策应用
均值 μ	用于核算整体财务预算。如核算每千人平均客单价。
中位数 M_e	用于评估组织真实生态。如评估IT研发团队薪酬，防范个别技术大牛拉高均值从而掩盖基层流失风险。
众数 M_o	用于供应链与库存SKU ² 决策。如服装浆纱主管，依据订单尺码众数锁定基础备料。

²最小库存单元，一件T恤，有3个颜色和2个尺码，则对应6个SKU。

离散趋势指标的风险量化应用

- 极差： $R = x_{\max} - x_{\min}$ 。简明直观，但易受偶发性极端噪音干扰。
- 方差： $\sigma^2 = \frac{\sum (x_i - \mu)^2}{n}$ 。平方化导致单位扭曲，不易直接解读。
- 标准差： $\sigma = \sqrt{\sigma^2}$ 。与原始数据单位统一。在商业中，标准差即风险，标准差即波动性！
- 标准误： $\sigma_{\bar{x}} = \frac{\sigma}{\sqrt{n}}$ ，衡量的是在多次抽样中，样本均值围绕总体均值波动的平均幅度。标准误越小，样本均值越接近总体均值，用样本均值推断总体均值越可靠。在商业问卷调查或质量检测中，降低标准误的最直接办法就是增加样本量。

管理应用场景	基于标准差 (σ) 的风险合规与质量精益化决策
金融风控视角	证券主管在进行营业部合规风控、财务主管在评估项目风控时，利用收益率的标准差量化资产波动风险。
精益制造质量	光电项目经理、底盘系统焊接工程师，利用核心工艺参数的标准差作为六西格玛 (6σ) 质量控制线的核心基石。

频数分布图




图 1.64 员工月薪频数分布图

- 横轴：具体的取值或者取值区间；
- 纵轴：频数/频率/概率；

频数分布形态指标的极端风险探测

- **峰度系数**：描述数据分布陡峭或平坦的指标，**参照基准为**与当前数据具有相同均值和标准差的**标准正态分布（峰度系数为0）**。

$$\frac{N(N+1)}{(N-1)(N-2)(N-3)} \times \frac{\sum_{i=1}^N (x_i - \mu)^4}{\sigma^4} - \frac{3(N-1)^2}{(N-2)(N-3)}$$

- **数理逻辑**：四次方剥离方向、只认破坏力。它对日常微小波动免疫，对极端背离进行放大（如 $4^4 = 256$ ），是肥尾风险的数理藏身所。
- **峰度系数 > 0 （尖峰厚尾）**：形状比正态分布更尖更窄。这意味着数据高度集中在均值附近，但同时**尾部比正态分布更厚**。在金融市场中，这暗示着“黑天鹅”事件（极端的暴涨或暴跌）发生的概率远高于正态分布的预测。
- **峰度系数 < 0 （平顶薄尾）**：形状比正态分布更平坦。这意味着数据分布比较均匀，**极端值出现的概率极低**。这种分布通常代表着一个系统处于高度可控、缺乏波澜的平稳状态。

数据分布峰度交互模拟

- **偏度系数**：描述数据分布对称性的指标，**参照基准为**与当前数据具有相同均值和标准差的**标准正态分布**。


$$\frac{N}{(N-1)(N-2)} \times \frac{\sum_{i=1}^N (x_i - \mu)^3}{\sigma^3}$$

- **数理逻辑**：三次方保留了偏离的正负号。正偏（大单暴利）立方后为正，负偏（极端差评）立方后为负，且将极端值放大（如 $4^3 = 64$ ）。
- **对称分布（偏度 = 0）**：左右一模一样，均值和中位数完全重合。
- **右偏（偏度 > 0）的典型代表**：公司薪酬，公司A薪酬数据（偏度为0.4662）。大多数员工拿的是底薪（峰在左边），但公司有几个拿高薪的高管（长拖尾在右边）。这几个超高薪水把“平均工资”拉高了。这时候看“均值”会被严重误导，**必须看“中位数”才能了解真实薪资水平**。
- **左偏（偏度 < 0）的典型代表**：产品合格率。大多数产品都是合格的，寿命很长（峰在右边的高分区），但偶尔有极少数残次品刚出厂就坏了（长拖尾在左侧）。**这些极差的次品会把“平均寿命”严重拉低**。

左偏还是右偏看“尾巴”，别看“山峰”。数据分布偏度交互模拟

- 峰度系数 C_K ：衡量分布的陡峭程度与“肥尾”风险。
 - $C_K > 0$ ：尖峰肥尾。意味着极端灾难事件发生的实际概率远高于正态分布假设。


商业解读：供应链核心零件的交期偏离天数。大部分时间里由于精益管理分毫不差（尖峰），但在最边缘处（尾部）由于突发地缘冲突或港口停工，依然顽强地存在着严重延误的离散小柱子（肥尾）。



7. 第七节：数据分布的属性特征

- $C_K < 0$: 分布被称为**平峰**分布。它的特点是：中间的峰掉下去了（平平塌塌），两边的尾巴被齐刷刷切断了（**薄尾/短尾**）。


商业解读：**政府财政兜底且严格限价**的轨道交通网点利润率。系统没有任何冲天的暴利惊喜（中间无尖峰），但也由于强政策约束和物理熔断，在边界之外齐刷刷切断，一根柱子都没有，从而在物理上绝对杜绝了任何黑天鹅暴雷的可能。



7. 第七节：数据分布的属性特征

- $C_K = 0$ ：数据分布完美契合**标准正态分布**。它的形状就是那条完美的、两边对称的经典钟形曲线。

商业解读：标准服务窗口的日常**排队等待时间偏离度**。完全由纯粹、独立的随机噪声引起，系统**极端可控**。常规的六西格玛质量控制最适合这种场景。



例如，某光电企业连续抽检了 10,000 枚核心光学镜头，记录下它们**偏心量的误差数据**。在工艺极其成熟、产线处于完全受控的稳定状态下，这组离散数据表现出的正是标准的 $C_K = 0$ （常峰中尾）状态。绝大多数镜头（如 7000 个）的误差死死贴在 0 附近（误差在 $\pm 0.2 \mu m$ 以内），中间的离散柱子高度适中。随着误差向左（负向偏差）或向右（正向偏差）放大，柱子的高度以平滑且匀称的坡度向两边对称递减。这表明系统没有受到任何方向性的“系统性偏向”（如机器松动）。

- 均值（绝对位置）：数据的重心在哪里？（受物理单位影响）
- 标准差（绝对跨度）：数据围绕重心散得有多开？（受物理单位影响，视觉上表现为高耸或扁平）
- 偏度系数（相对对称性）：剥离掉单位和跨度后，数据是左倾还是右倾？（无量纲系数，衡量不对称风险）
- 峰度系数（相对极端性）：剥离掉单位和跨度后，数据的尾部有多厚？（无量纲系数，衡量黑天鹅极端风险）
- 可比性：峰度系数和偏度系数对于不同数据具有可比性。

数据的统计相关性

- **因果相关性**：变量 X 与变量 Y 之间存在因果关系。 X 是原因， Y 是结果。如果 X 发生， Y 就会发生，**因果关系需要通过理论或实验来证实**。例如，固定资产投资增加和GDP增长。
- **统计相关性**：变量 X 的数值和变量 Y 的数值之间可以找出统计关系。统计关系是一种数量关系，**不需要、还没有或不可能解释**两者之间相关的原因。例如，公司高尔夫球水平与公司股票市场表现。

注意：具有因果相关性的变量不一定有统计关系，具有统计相关性的变量也不一定有因果关系。

线性相关性

- **线性相关系数 R** : 只反映两个变量之间线性统计关系, 取值范围为 $[-1, +1]$, $R > 0$ 表明两个变量按相同的方向变化。

1. 基础定义公式

变量 X 和 Y 的线性相关系数 R 定义为两者的协方差与各自标准差乘积的比值:

$$R = \frac{\text{cov}(X, Y)}{\sigma_x \sigma_y}$$

2. 协方差的计算公式

上述公式中的 $\text{cov}(X, Y)$ 称为变量 X 和 Y 的协方差, 其具体计算公式为:


$$\text{cov}(X, Y) = \frac{\sum_{i=1}^N (x_i - \mu_x)(y_i - \mu_y)}{N}$$

3. 完整的展开公式


将协方差的计算公式直接代入基础定义公式中, 即可得 R 的完整展开表达式:

$$R = \frac{\sum_{i=1}^N (x_i - \mu_x)(y_i - \mu_y)}{N\sigma_x\sigma_y}$$


不同线性相关系数示意图




(a) 无线性相关关系



(b) 负相关关系



(c) 正相关关系




(d) 完全正相关关系

使用自然语言绘制数据可视化图表

以阿里QoderWork为例演示，也可以使用其他大模型智能体。

- 下载安装：<https://qoder.com/qoderwork>；模拟数据
- 数据可视化图：使用本地数据或者模拟数据绘制各种数据可视化图；
- 数据透视表：使用本地数据或者模拟数据绘制各种数据透视表；



THE END