

第3讲 - 抽样和估计

张建章

阿里巴巴商学院
杭州师范大学

2026-05



1 第一节：统计抽样

2 区间估计与置信区间

3 置信水平、置信区间宽度和样本数

通过抽样，利用样本的参数来估计总体参数的数值，并根据事先给定的置信水平确定所估计的总体参数所在的区间。

抽样的基本概念

- **抽样：**根据一定的规则取得总体的一定数量的样本，通过对样本的统计分析来推测总体的统计特性。用抽样得到的样本来研究总体的统计特性是可能的（统计学理论和方法），也是必要的（直接研究总体不可行）。
- **总体和样本：**研究对象的全部被称为总体，可重复获取的总体中的一部分被称为样本。例如，在研究某一产品的合格率时，出厂的全部产品是总体，某一个日期或某一批次的产品就是样本。
- **抽样目标：**需要通过抽样来估计的总体的参数。在产品抽样调查中，抽样目标可以设定为产品的合格率、市场占有率等。
- **抽样误差：**由总体和样本数量的差别引起的，不可避免。
- **非抽样误差：**由于抽样方法不当、数据收集和处理过程中人为错误产生的误差。要设计尽量完善的抽样体系和方法，完善抽样调查的过程管理。

1. 第一节：统计抽样

- **抽样单元**：为了进行抽样，需要把总体划分成互不重叠的部分，每个部分被称为抽样单元。例如，在人口抽样调查中，一级单元为省，二级单元为市，三级单元为县。
- **抽样框**：全部抽样单元的一份详细资料。例如，一家饮料生产企业的产品市场占有率抽样调查的抽样框，应包括该厂和其他厂的厂名、商标、相关产品系列目录、产品名称、产品编码、生产地、销售地等资料。
- **抽样方法**
 - **主观抽样**：某一个抽样单元是否被抽中是由抽样组织者直接确定或者按组织者指定的规则来确定的。例如，在产品市场占有率调查中，可根据专家意见抽取某一个有代表性的产品。在产品合格率抽样中，可以在生产流水线上，每隔一定时间抽取一件产品进行检测等。
 - **随机抽样**：某一个抽样单元是否被抽中是由随机的方法来确定的。例如，用抽签的方式确定被抽检产品的品种、批次和编号等。如果样本数量 n 小于总体数量 N 的5%，放回与不放回的差别就不会很明显。
- **抽样方案设计**：进行一次抽样的指导性文件。包括抽样总体、抽样样本、抽样目标、抽样单元、抽样框和抽样方法等内容。

员工抽样模拟器

Z标准化

Z标准化将现实世界中具有**不同量纲（单位）**和**数量级**的数据都折算成一种没有任何单位的纯数字：

$$Z = \frac{X - \mu}{\sigma}$$

- 分子 ($X - \mu$)，**找准起跑线**：实际数值减去平均值。正数说明高于平均，负数说明低于平均，这去除了“绝对基数”（数量级）的影响。
- 分母 (σ)，**统一步伐**：除以标准差，这去除了“量纲和波动幅度”的影响。
- **最终含义**：**具体的数值距离平均水平有几个标准差（标准波动幅度）。**
- **正态分布 $N(\mu, \sigma^2)$ 标准化后服从标准正态分布 $N(0, 1)$ 。**

样本数据的统计分析

抽样是随机进行的，因此**样本数据的属性**，如样本数据的均值、方差、标准差、标准误等也是**随机变量**。**样本数越大**，样本的均值、方差、标准差越**接近总体相应的数值**。

样本均值的分布（中心极限定理）：无论总体服从何种分布，**只要样本数越来越大**，**样本均值 $\bar{x}$ 的分布就会逐渐接近正态分布**。这个正态分布的均值为总体均值 μ ，标准差为 $\frac{\sigma}{\sqrt{n}}$ ，其中 σ 为总体标准差， n 为样本数。

样本均值的分布（总体方差未知时）：样本均值 $\bar{x}$ 经过标准化后¹，即， $\frac{\bar{x}-\mu}{s/\sqrt{n}}$ ，服从 t 分布。回忆一下， t 分布的自由度（样本数）大于30时， t 分布和标准正态分布的区别就可以忽略不计了（**只要样本数越来越大**，**样本均值 $\bar{x}$ 的分布就会逐渐接近正态分布**）。

¹ 总体方差未知，用样本标准差 s 代替 σ

点估计、有偏估计和无偏估计

- **点估计**：直接将样本的统计指标作为总体相应指标的估计值，不考虑这种估计的误差。
- **区间估计**：在点估计的基础上，进一步考虑估计的误差范围，以及真实的总体参数落入这个误差范围的概率。
- **无偏估计**：估计量的均值等于总体参数，否则，称为有偏估计。

表 1: 常用总体参数的点估计

统计指标	总体参数	点估计 / 样本统计量
均值	$\mu = \frac{1}{N} \sum_{i=1}^N X_i$	$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$
方差	$\sigma^2 = \frac{1}{N} \sum_{i=1}^N (X_i - \mu)^2$	$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$
标准差	$\sigma = \sqrt{\frac{1}{N} \sum_{i=1}^N (X_i - \mu)^2}$	$s = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2}$


注： N 代表总体数量， n 代表样本数量，计算样本方差/标准差时，分母除以的是 $n-1$ 。

自由度

- **自由度**：如果已知样本均值 $\bar{x}$ 和 $n-1$ 个样本数据，第 n 个样本数据的值就完全确定了。这时，完全独立的样本数据只有 $n-1$ 个。**完全独立的样本数据称为样本的自由度**（degree of freedom，通常缩写为d.f.或df）。
- **自由度计算**：如果要用 n 个样本数据分别**独立地估计 k 个样本参数**，那么样本的自由度为 $n-k$ 。例如，由于样本方差和标准差的计算公式中需要用到样本均值 $\bar{x}$ ，**这时 n 个样本数据只有 $n-1$ 个是完全独立的**，因此样本方差和标准差的计算公式中分母要用 $n-1$ 。此时，样本的自由度为 $n-1$ ，因为，只依赖了“样本均值”这一个提前用这批数据算出来的参数（用 n 个样本数据独立地估计了1个参数）。
- **不要用错Excel函数**：这也是为什么在 Excel 中，计算样本方差和标准差的函数带有 .S 后缀（如 VAR.S、STDEV.S，代表 Sample），而计算总体的带有 .P 后缀（如 VAR.P、STDEV.P，代表 Population）。在**处理商业抽样数据时，千万别用错函数，用错就变成有偏估计了！**

基本概念

- **定义：**对于总体某个需要估计的参数（例如均值），给定一个概率值 $0 < 1 - \alpha < 1$ ，以及这个总体参数的一个点估计值 E ，得到这个总体参数的一个区间 $(E - \delta, E + \delta)$ ，使得这个区间包含这个总体参数的概率为 $1 - \alpha$ 。这个区间 $(E - \delta, E + \delta)$ 称为这个总体参数的置信区间， δ 称为区间值，概率 $1 - \alpha$ 称为置信水平。




- **例子：**给定置信水平为95%（ $1 - \alpha = 95\%$ ，即 $\alpha = 5\%$ ）。通过抽样，得到某种瓶装饮料容量均值为 $E = 250$ 毫升。经过计算，得到置信水平95%对应的区间值为 $\delta = 5$ 毫升，则瓶装饮料容积的置信区间为 $(245, 255)$ 毫升。这个区间估计的含义是：这种瓶装饮料容量的总体均值在245毫升到255毫升之间的概率为95%。
- **双尾概率：**置信区间的下界 $E - \delta$ 和上界 $E + \delta$ ，就是相应的概率分布（例如 t 分布或正态分布）双尾概率为 α 的相应的随机变量值。

总体均值的置信区间

设总体数量为 N ，总体均值为 μ ，总体标准差为 σ 。为了对总体均值 μ 进行区间估计，需要进行抽样。设样本数为 n ，样本均值为 $\bar{x}$ ，样本标准差为 s

- 如果总体方差未知：样本均值随机变量标准化之后服从均值为 μ 、标准差为 $\frac{s}{\sqrt{n}}$ 、自由度为 $n - 1$ 的 t 分布。设置信水平为 $1 - \alpha$ ，则双尾概率为 α ，置信区间的区间值 δ 为 $t_{\text{双尾}\alpha, n-1} \cdot \frac{s}{\sqrt{n}}$ 。
- 如果总体方差已知或总体方差虽未知但样本数 n 足够大 ($n > 30$)：样本均值随机变量标准化之后服从均值为 μ 、标准差为 $\frac{s}{\sqrt{n}}$ 的正态分布。设置信水平为 $1 - \alpha$ ，则双尾概率为 α ，置信区间的区间值 δ 为 $z_{\text{双尾}\alpha} \cdot \frac{s}{\sqrt{n}}$ （即， $z_{\text{左尾}1-\alpha/2} \frac{s}{\sqrt{n}}$ ）。
- 计算尾概率的Excel函数： t 分布双尾反函数 $\text{T.INV.2T}(\alpha, n - 1)$ ，标准正态分布左尾反函数 $\text{NORM.S.INV}(1 - \alpha/2)$ 。（Excel中正态分布只有左尾反函数）



置信区间值 δ 的推导过程（略）

样本均值是一个随机变量 $\bar{X}$ ，对其进行标准化后得 t 统计量 $\frac{\bar{x} - \mu}{s/\sqrt{n}}$ ，该统计量服从自由度为 $n - 1$ 的 t 分布。设置信水平为 $1 - \alpha$ ，则有：

$$P\left(-t_{\text{双尾}\alpha, n-1} \leq \frac{\bar{X} - \mu}{s/\sqrt{n}} \leq t_{\text{双尾}\alpha, n-1}\right) = 1 - \alpha$$

$$P\left(\bar{X} - t_{\text{双尾}\alpha, n-1} \frac{s}{\sqrt{n}} \leq \mu \leq \bar{X} + t_{\text{双尾}\alpha, n-1} \frac{s}{\sqrt{n}}\right) = 1 - \alpha$$

因此，置信区间值 $t_{\text{双尾}\alpha, n-1} \cdot \frac{s}{\sqrt{n}}$ 。

同理，可得 $z_{\text{双尾}\alpha} \cdot \frac{s}{\sqrt{n}}$ （即， $z_{\text{左尾}1-\alpha/2} \frac{s}{\sqrt{n}}$ ）。

区间估计的精度

在区间估计中，**区间值的大小表示区间估计的精度**。区间值越小，区间估计越精确。由 $\delta = t_{\text{双尾}\alpha, n-1} \cdot \frac{s}{\sqrt{n}}$ 可知，区间估计的精度与以下三个因素有关：

- $1 - \alpha$ ：置信水平取得越高（ t 越大），置信区间越大，区间估计的精度越低。
- 样本分散程度 s ：样本标准差越大，置信区间越大，区间估计的精度越低。
- 样本数 n ：样本数越大，置信区间越小，区间估计的精度越高。

商业案例

你是某头部短视频 APP 的商业分析师。产品部门最近提出一个假设：“随着短视频内容的下沉，老年群体（60岁以上）的黏性正在迅速追赶年轻群体（18-24岁），应该调整广告投放的权重。”为了验证这个假设，你从数据库的后台日志中抽取了昨天不同年龄段活跃用户的“日均停留时长”（单位：分钟），并在 95% 的置信水平下构造区间估计。

目标群体特征	18岁以下 (Z世代)	18—24岁 (大学生 / 初入职场)	25—30岁 (职场主力)	31—60岁 (中年家庭)	60岁以上 (银发族)
抽样流量 n	136	257	164	111	64
均值 $\bar{x}$ (分钟)	65.8	209.2	202.9	163.2	152.8
标准差 s (分钟)	23.7	22.2	28.9	27.8	36.6

(1) 借助Excel函数 $z = \text{NORM.S.INV}(1 - 0.05/2) = 1.96$ 求解（所有组的样本数都大于30）；

两组人群的日均停留时长区间估计结果为，18-24岁：[206.5, 211.9]；银发族：[143.8, 161.8]

解读：第一，年轻群体的护城河依然极其稳固，18-24岁年轻人的日均时长置信区间是 [206.5, 211.9] 分钟，区间值为2.7 分钟，比较小，因为这组数据不仅样本量大（257人），而且用户行为极其同质化（标准差最小）。第二，银发族的时长数据‘水分’很大，产品部的假设目前不能成立，40 岁以上群体的置信区间是[143.8, 161.8] 分钟，区间值为9分钟，比较大，。因为目前的抽样量太少（只有 64人），而且中老年人的使用习惯极度两极分化（标准差高达 36.6，最高）。第三，这个上限 161 分钟和年轻人的下限 206 分钟之间，差距大，现在就重仓中老年广告是极其危险的。如果产品部坚持认为中老年有潜力，**建议请批一笔定向流量预算，把60岁以上的测试样本量 n 从 64提升到500，缩小区间值**，才能看清银发族真实的留存底线，再决定要不要砸钱！”

比例的置信区间

在实际问题中，经常需要研究总体中具有某种特征的个体（简称为特征个体）占总体比例的问题。例如，某一品牌产品的销量占同类产品总销量的比例；

随机变量定义：设特征个体占总体的比例为 π ，简称为总体比例。抽取样本的数量为 n ，其中特征个体的数量为 x ，在样本中特征个体的比例为 $p = \frac{x}{n}$ ，简称为样本比例。样本比例 p 是总体比例 π 的一个无偏估计。

随机变量分布：样本中的特征个体数量 x 服从二项分布 $B(x, n, \pi)$ 。因此， x 的均值为 $n\pi$ ，方差为 $n\pi(1 - \pi)$ ，标准差为 $\sqrt{n\pi(1 - \pi)}$ 。因此，样本比例 $p = \frac{x}{n}$ 的均值为 $\bar{p} = \frac{n\pi}{n} = \pi$ ，方差为 $s^2 = \frac{n\pi(1-\pi)}{n^2} = \frac{\pi(1-\pi)}{n}$ ，标准差为 $s = \sqrt{\frac{\pi(1-\pi)}{n}}$ 。

置信区间：当样本数 n 增大时，样本比例 p 的抽样分布接近正态分布。将样本比例 p 作为总体比例 π 的点估计，设定置信水平 $(1 - \alpha)$ ，则 p 的置信区间值 δ 为：

$$z_{\text{左尾}1-\alpha/2} \cdot \sqrt{\frac{p(1-p)}{n}}$$

商业案例

公司今年在“出海”战略下，针对欧美市场研发了一款新型多功能便携工具（A产品）。为了测试市场反应，公司在亚马逊的四个不同区域站点（北美、欧洲、日本、澳洲）投放了为期一周的首页广告引流。根据下面的初步测试数据，在 95% 的置信水平下，估算各站点全面推广后 A 产品的真实转化率的置信区间。

站点区域	北美站	欧洲站	日本站	澳洲站
实际购买人数（特征个体数 x ）	1252	1326	1130	674
总点击人数（样本总数 n ）	20000	25000	18000	12000
初步转化率（样本比例 p ）	6.26%	5.30%	6.28%	5.62%

(1) 借助Excel函数 $z_{\text{左尾}1-\alpha/2} = \text{NORM.S.INV}(0.975) = 1.96$;

北美站:[5.92%, 6.60%], 欧洲站:[5.03%, 5.58%]; 日本站:[5.92%, 6.63%], 澳洲站:[5.20%, 6.03%]

解读：第一，北美站和日本站是我们的绝对主力市场。有 95% 的把握认为，这两个站点的真实转化率保底也能达到 5.9% 左右。建议对这两个站点追加大规模的广告预算。第二，欧洲站表现最为疲软，需要警惕。转化率上限（5.58%），甚至比北美和日本的下限（5.92%）还要低！这说明欧洲站的用户对这款产品的购买意愿显著低于其他地区，建议暂缓在欧洲站的大规模铺货。第三，关于数据的精度。区间值不到1%，区间估计很精准，因为花了足够多的钱买了大量的测试点击（ n ）。

商业案例

公司近期投入了一条全新全自动生产线。在早期的试运行（小规模抽样）中，质检主管向总经理（一把手视角）汇报：“目前我们随机检测了 $n = 12,000$ 件产品，发现缺陷件数 $x = 674$ 件，表面缺陷率（样本比例 p ）为 5.62%。”根据 95% 的置信水平，目前的误差半径 δ 大约是 0.41%（即真实缺陷率在 5.21% 到 6.03% 之间）。”总经理说：“不行！0.41% 的误差太粗糙了，重新做一次全面大抽样，必须把误差半径 δ 压缩到 0.1% 以内！依然保持 95% 的置信水平。”

(1) 由置信区间值的计算公式，推导抽样数量：

$$\delta = z \cdot \sqrt{\frac{p(1-p)}{n}}$$

$$n = \frac{z^2 \cdot p(1-p)}{\delta^2}$$

(2) 代入已知数值，计算 n ：

$$n = \frac{1.96^2 \cdot 0.0562 \cdot (1 - 0.0562)}{0.001^2} \approx 203,644 \text{ 件}$$

解读：接下来的质检大抽样，必须连续不间断地检测 203,644 件产品！第一，这是一笔巨大的成本开支。相比于之前的 1.2 万件，我们的检测量翻了近 17 倍！因为统计学里存在‘平方根边际递减效应’，误差想要缩小到原来的 1/4，样本量就得翻 16 倍。需要额外申请 3 班倒的质检人手和自动化检测仪器。第二，建议将误差放宽到 0.2%。需要检测的样本量会跌到约 5.1 万件！相比 0.1%，节约四分之三的质检成本。

两样本均值之差的置信区间

在很多情况下，需要研究两个总体的均值差异有多大。例如，某种商品的平均销量在做广告前和做广告后的差异有多大。假设两样本来自两个不同的总体，两个总体的统计参数如下表。

	总体1	总体2
均值	μ_1	μ_2
标准差	σ_1	σ_2
均值的点估计	$\bar{x}_1$	$\bar{x}_2$
样本数	n_1	n_2

- 随机变量定义：需要估计的总体参数为两总体均值之差 $\mu_1 - \mu_2$ 。 $\mu_1 - \mu_2$ 的点估计由两样本均值之差 $\bar{x}_1 - \bar{x}_2$ 给出。
- 随机变量的分布：区分两总体方差相等和不相等两种情况。

- 两总体方差不等：设置信水平为 $1 - \alpha$ ，置信区间的区间值 δ 为

$$t_{\text{双尾}\alpha, \text{df}} \cdot \sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}$$

$t_{\text{双尾}\alpha, \text{df}}$ 是自由度为 df 的 t 分布值。自由度 df 的计算公式为：

$$\text{df} = \frac{(s_1^2/n_1 + s_2^2/n_2)^2}{\frac{(s_1^2/n_1)^2}{n_1 - 1} + \frac{(s_2^2/n_2)^2}{n_2 - 1}}$$

计算结果小数向下取整。

- 两总体方差相等：设置信水平为 $1 - \alpha$ ，置信区间的区间值 δ 为，

$$t_{\text{双尾}\alpha, df} \cdot \sqrt{\frac{s_p^2}{n_1} + \frac{s_p^2}{n_2}}$$

其中， $t_{\text{双尾}\alpha, df}$ 是自由度为 $(n_1 + n_2 - 2)$ 的 t 分布值。尽管两总体的方差相等，分别来自两总体的样本的方差 s_1^2 和 s_2^2 仍然有可能不相等，以两样本自由度 $n_1 - 1$ 和 $n_2 - 1$ 分别占两样本总自由度 $n_1 + n_2 - 2$ 的比例为权重，加权估计一个合并标准差 s_p 。

$$s_p = \sqrt{\frac{(n_1 - 1)s_1^2 + (n_2 - 1)s_2^2}{n_1 + n_2 - 2}}$$

商业案例

工厂量身定制了一套“AI 智能供应链与排产优化系统”。为评估这套系统是否真正显著降低了每百万元产值的综合运营成本，调取了该生产线在系统上线前24个月和系统上线后12个月的月度百万元产值运营成本数据（单位：万元）：

- 系统上线前（总体1）：抽取了 $n_1 = 24$ 个月的数据，月均百万元产值成本 $\bar{x}_1 = 24.7167$ 万元，样本标准差 $s_1 = 2.0660$ 万元。
- 系统上线后（总体2）：抽取了 $n_2 = 12$ 个月的数据，月均百万元产值成本 $\bar{x}_2 = 27.0667$ 万元，样本标准差 $s_2 = 1.4176$ 万元。

请在 95% 的置信水平下，计算系统上线前后月度百万元产值成本之差（ $\mu_1 - \mu_2$ ）的置信区间。并分别在“两总体方差不相等”与“两总体方差相等”两种风控假设下，论证该系统是否切实达成了“统计学意义上的显著降本”。

（1）风控视角——假设两总体方差不相等（数字化改变了流程波动性）

数字科技系统上线后，生产流程更加标准化，月度成本的波动明显变小（ $s_2 = 1.4176 < s_1 = 2.0660$ ）。因此，方差不相等的假设更符合商业常识。

① 计算自由度（df）：

$$df = \frac{(s_1^2/n_1 + s_2^2/n_2)^2}{\frac{(s_1^2/n_1)^2}{n_1-1} + \frac{(s_2^2/n_2)^2}{n_2-1}} = \frac{(2.0660^2/24 + 1.4176^2/12)^2}{\frac{(2.0660^2/24)^2}{24-1} + \frac{(1.4176^2/12)^2}{12-1}} = 30.3861$$

小数部分向下取整，确立自由度 $df = 30$ 。

商业案例

② 计算 $t_{\text{双尾}\alpha, \text{df}}$ ：在 Excel 中输入 `=T.INV.2T(0.05, 30)`，得到 $t_{\text{双尾}0.05, 30} = 2.0423$ 。

③ 计算置信区间：

$$(\bar{x}_1 - \bar{x}_2) \pm t_{\text{双尾}\alpha, \text{df}} \sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}$$

$$(24.7167 - 27.0667) \pm 2.0423 \times \sqrt{\frac{2.0660^2}{24} + \frac{1.4176^2}{12}} = -2.3500 \pm 1.2001 \text{ 万元}$$

置信区间为：**(-3.5501, -1.1499)** 万元。

(2) 基准视角——假设两总体方差相等（纯粹进行均值合并评估）

置信区间为：**(-3.7014, -0.9986)**万元。

解读：按照 $(\bar{x}_1 - \bar{x}_2)$ （即‘上线前成本’减去‘上线后成本’）的定义，差值完全为负，说明系统上线后的百万元产值综合成本，在 **95%** 的置信水平下，实现了绝对的、无可争议的下降！即使按照最保守的场景估计（方差相等下的区间上界），系统每月在每百万元产值上也能稳稳地省下至少 **1 万元** 的成本。

两样本比例之差的置信区间

- **随机变量定义**: 分别从两总体中抽取数量为 n_1 和 n_2 的两个样本。在两样本中特征个体的数量分别为 x_1 和 x_2 。样本比例分别为 $p_1 = x_1/n_1$, $p_2 = x_2/n_2$ 。
- **随机变量分布**: 当样本数和特征个体数都比较大, 如 x_1 , $n_1 - x_1$, x_2 , $n_2 - x_2$ 都大于5时, 两样本比例之差 $p_1 - p_2$ 的分布近似服从正态分布, 设置信水平为 $1 - \alpha$, 置信区间的区间值 δ 为,

$$z_{\text{左尾}1-\alpha/2} \cdot \sqrt{\frac{p_1(1-p_1)}{n_1} + \frac{p_2(1-p_2)}{n_2}}$$

商业案例

营销团队在天猫和抖音上进行了一场引流测试，想要验证一个核心战略假设：“女性用户和男性用户在看到相同卖点广告时，最终的下单转化率（购买比例 π ）是否存在本质差异？”如果男女转化率没差异，公司就采取“男女通投”策略；如果有显著差异，则必须拆分预算进行精准定向投放。项目上线第一周，数据分析师在后台抽取了“小流量灰度测试”的广告数据：

- 女性受众组（总体1）：曝光点击人数 $n_1 = 4326$ 人，最终下单购买 $x_1 = 649$ 人，样本转化率 $p_1 = 15.002\%$ 。
- 男性受众组（总体2）：曝光点击人数 $n_2 = 7522$ 人，最终下单购买 $x_2 = 1104$ 人，样本转化率 $p_2 = 14.677\%$ 。

表面上看，女性的转化率（15.002%）比男性（14.677%）高了0.325%。运营主管兴奋地想要立刻调整预算。请在**95%置信水平下计算两样本比例之差（ $\pi_1 - \pi_2$ ）的置信区间**。

- 1 判定分布：由于 x 和 $n - x$ 均远大于5，根据中心极限定理，比例之差服从正态分布。
- 2 确立 z 临界值：

$$z_{\text{左尾}1-\alpha/2} = \text{NORM.S.INV}(0.975) = 1.9600$$

- 3 计算置信区间：（-1.006%，1.656%）

解读：区间包含了“0”。虽然表面上看女性高了一点点，但由于目前的测试流量太小，这个 0.33% 的差距极有可能是随机噪音引起的。在统计学上，无法断定男女转化率有高低之分。

商业案例

根据前面的计算结果，决定在“天猫超级品牌日”期间采用“男女通投”全面铺开，将产品推向全网全量公域流量。团队在一天内就捕获了百万级的全量用户点击行为。令人惊奇的是，此时全量数据算出来的男女最终购买比例与第一周灰度测试完全一模一样，依然分别是 $p_1 = 15.002\%$ 和 $p_2 = 14.677\%$ 。但是，两组的样本规模发生了巨大变化：

- 女性受众组：全量点击人数 $n_1 = 423,765$ 人，购买人数 $x_1 = 63,572$ 人。
- 男性受众组：全量点击人数 $n_2 = 743,200$ 人，购买人数 $x_2 = 109,076$ 人。

再次在 95% 置信水平下，为一模一样的差值（0.325%）重新计算置信区间得到(0.191%, 0.459%)

解读：这个案例展示了为什么新零售企业必须做“大样本数据风控”。（一些统计问题在小样本情况下没有明确的结论，增加样本数后可能就会获得有统计意义的结果。）

这两次实验中，虽然男女用户的表面转化率之差都是0.33%，但在不同的样本规模下，数据给出的决策启示是完全不同的：

- ① 在小流量测试时，误差半径高达1.33%，导致算出来的置信区间为(-1.006%, 1.656%)，估计精度低，包含了0。当时如果盲目拆分男女广告预算，有极大的概率是主观臆断。
- ② 但在全量大数据下，样本量冲到了百万级别。误差半径被压缩到了千分之一（0.134%）！新的置信区间为(0.191%, 0.459%)，完全脱离了0，全部落在了正数区间内！

这意味着，我们现在有95%的把握断定：在真实的市场全量行为中，女性对这款抗引力精华的购买意愿确实显著高于男性！虽然这个优势只有区区0.3%左右，但在每年上亿元的公域流量大盘中，这0.3%的转化率差异就对应着上百万元的净利润波动。

方差的置信区间

- **随机变量定义：**方差是数据的重要特性，通过抽样样本对总体的方差进行区间估计也是实际中经常需要解决的问题。设总体数量为 N ，总体方差为 σ^2 ，标准差为 σ 。样本数量为 n ，样本为 $x_1, x_2, \dots, x_n$ 。样本均值为 $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$ ，样本方差为 $s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$ 。用样本方差 s^2 作为总体方差 σ^2 的点估计。
- **随机变量分布：**方差的抽样分布为自由度为 $n-1$ 的 χ^2 分布， χ^2 分布的概率密度函数不是对称的曲线。因此方差的置信区间上下界不是“点估计 $\pm$ 区间值”的形式，而是直接计算置信区间的上下界。设置信水平为 $1-\alpha$ ，置信区间为，

$$\left(\frac{(n-1)s^2}{\chi_{1-\alpha/2, n-1}^2}, \frac{(n-1)s^2}{\chi_{\alpha/2, n-1}^2} \right)$$

- 计算 χ^2 临界值的Excel函数:CHISQ.INV(probability, degrees_freedom) 返回 χ^2 分布左尾概率的随机变量值。

商业案例

公司新投产的高阶光学镜头制程中，某项关键核心垫片的厚度误差总体方差 σ^2 绝对不能超过 $20 \mu\text{m}^2$ （平方微米）。一旦真实总体方差超过这个红线，意味着产品有极高概率出现批量不匹配，导致天价退货。风控主管协助进行了随机抽样质检：

- 质检抽样量 n ：64件精密组件。
- 样本方差 s^2 ：13.3800。

总经理在听取汇报时一针见血地指出：“虽然样本方差13.38看起来小于20，但这只是64件货的局部表面数据。我想知道，如果产线全面开满，全量总体的真实波动方差 σ^2 究竟在什么范围内？在95%的置信水平下，我们能打包票这条产线绝对安全吗？”

- 利用Excel的卡方反函数计算临界值：自由度 df ： $n - 1 = 64 - 1 = 63$ ，95% 置信水平下， $\alpha = 0.05$ 。双尾劈开，左尾巴留 $\alpha/2 = 0.025$ ，右尾巴留 $1 - \alpha/2 = 0.975$ 。右端大刻度： $\chi_{0.975, 63}^2 = 42.9503$ ，左端小刻度： $\chi_{0.025, 63}^2 = 86.8296$ 。
- 计算置信区间：(9.7080, 19.6259)

解读：第一，在 95% 的高可靠性要求下，这条新产线真实总体方差的区间跨度是 (9.71, 19.63)，满足要求最低要求 $20 \mu\text{m}^2$ 。由于卡方分布的不对称性，估计区间有点偏向右侧的高风险端（方差点估计都落在置信区间的偏左端），但上限19.63依旧小于20。第二，区间的宽度（从9.7到19.6）相对较宽，区间估计精度有待提高，如果大客户打算将红线进一步压缩到15，先不需要急着去更换更贵的机床（缩小 s ），而是应该把抽样样本数 n 提升到200以上，进行更精准的区间预测后再做决策。

置信区间总结

表 2: 区间估计和置信区间一览表

区间估计类型	分布类型	自由度	置信区间（上下界）计算公式
均值	标准差已知	正态分布	$\bar{x} \pm z_{\text{左尾}1-\alpha/2} \frac{s}{\sqrt{n}}$
	标准差未知	t 分布 $df = n - 1$	$\bar{x} \pm t_{\text{双尾}\alpha, n-1} \frac{s}{\sqrt{n}}$
比例	正态分布		$p \pm z_{\text{左尾}1-\alpha/2} \sqrt{\frac{p(1-p)}{n}}$
两样本均值之差	等方差	t 分布 $df = n_1 + n_2 - 2$	$(\bar{x}_1 - \bar{x}_2) \pm t_{\text{双尾}\alpha, df} s_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}$, 其中 $s_p = \sqrt{\frac{(n_1 - 1)s_1^2 + (n_2 - 1)s_2^2}{n_1 + n_2 - 2}}$
	不等方差	t 分布 $df = \frac{(s_1^2/n_1 + s_2^2/n_2)^2}{\frac{(s_1^2/n_1)^2}{n_1 - 1} + \frac{(s_2^2/n_2)^2}{n_2 - 1}}$	$(\bar{x}_1 - \bar{x}_2) \pm t_{\text{双尾}\alpha, df} \sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}$
两样本比例之差	正态分布		$(p_1 - p_2) \pm z_{\text{左尾}1-\alpha/2} \sqrt{\frac{p_1(1-p_1)}{n_1} + \frac{p_2(1-p_2)}{n_2}}$
方差	χ^2 分布	$df = n - 1$	$\left[\frac{(n-1)s^2}{\chi_{1-\alpha/2, n-1}^2}, \frac{(n-1)s^2}{\chi_{\alpha/2, n-1}^2} \right]$

注：如果样本数大于30，则表中的 t 分布也可用正态分布代替，从而无须计算自由度。

三者之间相互关联

- 回忆一下：置信水平表示估计的可靠性，置信区间宽度表示估计的精度。
- 相互关联：在样本数不变的情况下（之前的情况），置信水平设定得越高，置信区间宽度越大（根据置信水平求点估计的置信区间）。置信水平确定以后，样本数越大，置信区间宽度越小（根据要求的估计精度/置信区间宽度，确定所需的样本数）。
- 两种常见的求样本数情形：一种是均值区间估计中，已知均值置信区间的精确度，要求计算所需要的样本数；另一种是比例区间估计中，已知比例置信区间的精确度，要求计算所需要的样本数。
- 求解思路：根据置信区间值 δ 的公式，将等式变为不等式（ $\delta \leq \dots \rightarrow n \geq \dots$ ）。
 - 均值区间估计 $n \geq 30$:

$$n \geq \left(\frac{z_{\text{左尾}1-\alpha/2} \cdot s}{\delta} \right)^2$$

- 比例区间估计 $n \geq 30$:

$$n \geq \frac{(z_{\text{左尾}1-\alpha/2})^2 p(1-p)}{\delta^2}$$

课堂练习

- 安装随书电子资料中的Excel插件数据通；
- 使用该插件完成教材例3.12和例3.13。

THE END